



반려견 유전자 분석 프로젝트

Project Overview & Analysis Results

프로젝트 파이프라인 OVERVIEW

1



데이터 이해 및 수집

- 1.1. 데이터 추출 과정 및 핵심 용어
- 1.2. 데이터 구조 및 컬럼

2



데이터 정제

- 2.1. 데이터 패턴 탐색
- 2.2. 와이드 포맷 생성
- 2.3. 전처리 : 컬럼/마커 정리

3



데이터 분석

- 3.1. 유전병적 소인 분석
- 3.2. 개체 간 유사 품종 분석

4



최종 산출물

- 4.1. 최종 산출물 : Streamlit
- 4.2. 회고록

0.프로젝트 개요 및 타깃 선정

프로젝트명 및 핵심 목표

반려견 유전적 특성을 파악한 맞춤형 건강관리 서비스 구현

- ✔ 유전체 데이터 분석을 기반으로 증상 발현 전 고위험 질환 리스크를 예측
- ✔ 개체별 특성과 유전적 요인을 고려한 맞춤형 헬스케어 제공

🐾 주요 타깃: 척추 및 근골격계 질환 - 슬개골 탈구, 십자인대 손상 등


핵심 기여

- ✔ 다빈도 질환이 아닌, 고액 진료비가 발생하는 치명적 질환의 사전 예방
- ✔ 수술이 필수적인 고비용 질환 예측을 통한 보호자 경제적 부담 경감
- ✔ 조기 발견 및 예방적 조치를 통한 반려견 삶의 질 향상

📊 품질 관리된 유전체 데이터는 품종별/연령별 맞춤형 예방 관리 서비스의 기반 자료로 사용

시장성 데이터

펫보험 지급액 기준 상위 질환 분석



출처: www.dailyvet.co.kr

타깃 질환 선정 근거

- ✔ 시장 조사 결과, 2021년부터 2025년까지 질환 빈도는 낮으나 지급액 최상위 (1~2위) : 슬개골 탈구
- ✔ 수술이 필수적인 고비용 질환으로 경제적 가치 높음

1.1.데이터 추출 과정 및 핵심 용어

데이터 추출 과정



01 계획 및 준비 → 02 DNA 추출 → 03 Raw SNP Data 생성
→ 04 Genotype Calling → 05 SNP Table 생성

핵심 용어



SNP 단일염기다형성

DNA 서열에서 단일 뉴클레오타이드(A/T/G/C)가 변이된 부분. 개체 간 유전적 다양성과 질병 감수성의 기초가 됩니다. 개체군 내 1% 이상의 빈도로 발견되는 DNA 서열의 변이를 의미합니다.



Array 마이크로어레이

수만~수백만 개의 DNA 프로브가 고정된 칩을 이용하여 한 번에 많은 SNP를 검사하는 기술. 다양한 유전자형의 병렬 측정을 통해 대규모 유전체 정보를 효율적으로 분석합니다.



CEL 파일

Affymetrix 마이크로어레이에서 생성되는 raw intensity 값을 저장하는 파일 형식. 각 프로브의 형광 강도 측정값을 포함하며 기초 데이터로 활용됩니다.



Genotype Call

마이크로어레이에서 측정된 raw intensity 값을 분석하여 실제 유전자형(AA/AB/BB)을 결정하는 과정. 알고리즘을 통해 각 SNP 위치에서 개체가 가진 유전자형을 판별합니다.

1.2.데이터 구조 및 컬럼

SNP 검사 목적

- 유전체 특정 위치에 존재하는 단일 염기 변이(SNP)를 탐지하는 것이 기본 목적
- 개체 간 유전적 차이를 확인하여 유전적 다양성 파악
- 질병·품종·형질과 연관된 변이를 식별하는 것이 핵심 목적

제공받은 SNP 데이터

- 데이터 규모: 총 94개 파일
- 파일 형식: 파일명_개별셀.CEL.TXT
- 데이터 용도: 전처리·병합을 거쳐 유전자형 행렬(genotype matrix) 구축

SNP 데이터 주요 컬럼

컬럼명	의미
Chr	SNP가 위치한 염색체 번호
Start	변이가 발생한 염기 위치(Position)
Ref / Alt	기준염기(Ref) / 변이염기(Alt)
Allele_A / Allele_B	Microarray 프로브에서 감지된 두 염기
call_code(AA/AB/BB)	검출된 실제 유전자형(Genotype)
CR / FLD / HetSO	품질(QC) 지표
probeset_id	SNP 마커 고유 ID

💡 유전자형 데이터는 이후 전처리 단계에서 0(AA), 1(AB), 2(BB), -1(NoCall)과 같이 수치형으로 인코딩되어 머신러닝 모델의 입력값으로 사용됩니다.

2.데이터 정제

유전체 데이터 정제 파이프라인의 작업 흐름 및 목적

</> 기술 스택

Python 데이터 처리

Pandas

Numpy

os, glob, re

matplotlib, seaborn

Jupyter



프로젝트 환경 설정

pandas, numpy 라이브러리 활용

matplotlib, seaborn 최적화

tqdm 프로그레스바

자동 OS 감지 및 한글 폰트 적용

⚙️ 분석 파이프라인

1

데이터 패턴 탐색

파일 구조 분석 및 일관성 검증을
통한 유전체 데이터 기초 탐색



2

와이드 포맷 생성

개별 샘플 파일에서 통합 유전자
형 행렬로의 변환 과정



3

데이터 전처리

데이터 정리 과정, 인코딩 전략,
최종 산출물

2.1.데이터 패턴 탐색



파일 구조 관찰

초기 관찰: call_code를 제외한 모든 컬럼이 파일 간 동일한 값을 가짐

→ 마치 하나의 템플릿처럼 일관된 구조를 보임



관찰 결과

전체 파일 행 개수 분포(총 94개 파일 스캔 완료)

479,919 행: 51개 파일 (54.3%)


478,231 행: 43개 파일 (45.7%)




검증 절차

행(row) 개수 일치성 검증으로 모든 파일의 행 개수를 비교하여 분포 확인
probeset_id 완전 일치성 검증, 각 probeset_id별 값 일치율 계산 및 분석

파일 행 개수별 분포



2.2.와이드 포맷 생성



키 컬럼: probeset_id

모든 샘플 파일에서 일관되게 유지되는 유전자 마커 식별자를 키로 사용하여 데이터 병합

샘플 ID 표준화

파일명에서 고유 샘플 ID를 추출하여 컬럼명으로 사용
일관된 명명 규칙 적용

인코딩

우리는 변이에 관심, Alt Allele라고 변이된 대립유전자의 개수가 call_code안에 얼마나 있는지 count하는 방식을 채택함

2.3.전처리 : 컬럼/마커 정리

- ✓ 현재 상태 및 전처리 방침
- 현재 상태: 제공받은 데이터는 샘플 단위 전처리 완료
 - QC 마커 기반 행 제거 미실행
이유: 과도한 QC 시 품종/질병 관련 희귀 변이 손실 위험
 - 선택적 제거만 수행: 활용 불가 컬럼(열 단위) 및 마커(행 단위)

컬럼 제거 (열 단위)

1 완전 결측 컬럼

총 13개

대상: 모든 값이 100% Null인 컬럼
이유: 분석 가치 없음

2 단일값 컬럼

총 8개

대상: 모든 행에서 동일한 값을 가진 컬럼
문제점: 변별력 없음, 예측력 없음

3 중복/불필요 컬럼 제거

컬럼	제거 이유	대체
Allele_A/B	장비 라벨 (중복)	Ref/Alt
Affy_SNP_ID	식별자 중복	Probeset_ID
affy_snp_id	대소문자 중복	-

검증 결과:
✓ [Check 1] Affy_SNP_ID vs affy_snp_id: 대소문자만 다른 완벽 중복 컬럼
✓ [Check 2] Probeset_ID / Affy_SNP_ID: 모두 Primary Key 역할 (중복 제거 가능)

마커 제거 (행 단위)

1 마스터 ID 추출

목적: Wide format 검증용 기준 Probeset 목록 확보

``\*E04.CEL.txt`` 파일에서 마스터 ID 추출
컬럼명 통일 (`probeset\_id` → `Probeset\_ID`)
기준 행 개수 설정
master id 목록과 일치하는 행만 보존, 나머지 행은 제거

2 chr_id 결측 행 처리

배경: Mapping 우선순위
dbSNP_RS_ID → chr_id/start/stop

이슈 분석:
✓ dbSNP_RS_ID 결측: 허용 (대체 수단 존재)
✗ chr_id 결측: 제거 필요 (최종 매핑 수단 부재)

카테고리 분류:

1. 완전 누락형 (대부분)
위치 정보: ✗
ID 정보: ✗
Annotation: 없음
처리: 제거

2. 부분 정보형 (일부)
위치 정보: ✗
Disorder 정보: ✓
딜레마: 질병 연관성은 있으나 매핑 불가

cust_id 분석 결과:
출처 불명확: 공인된 표준 ID 아님, 고객사 임의 기재 가능성
검증 불가: 위치/ID 정보 부재, Disorder 이름만으로 판단 불가
처리 방침: 분석 신뢰성 확보를 위해 해당 행 제거

3.1.데이터 분석(유전병적 소인 분석)

유전체 데이터 분석 파이프라인의 작업 흐름 및 목적



OMIA-Ensembl-SNP 3단계 LD-proxy 매핑 전략

1단계: rsID 완전 일치 (최고 신뢰도)

2단계 : 염색체 + 위치 일치 (높은 신뢰도)

3단계 : 유전자 구간 내 최근접 SNP (LD proxy)



기술 스택



Python 데이터 처리



Pandas, Numpy



Ensembl GTF



MYSQL




matplotlib, seaborn



pyliftover



분석 파이프라인



3.1.1.매핑 1단계

1 OMIA 데이터 추출

OMIA SQL DB에서 개(dog, 9615) 변이·유전질환 정보를 추출하여 variant-phene-gene 메타데이터를 확보

핵심 필터링 전략 –

종(Species) 필터링: gb_species_id = 9615 (개)

▼ 좌표 필터링: 좌표 정보(g_or_m)가 있는 변이만

추출된 변이정보(위치·유전자·질환·유전양식)는 이후 *Ensembl-SNP* 매핑의 기반 데이터로 활용

1차: Max Recall 전략

8개 카테고리 정규표현식으로 광범위한 후보군 선정

추출된 행
 **527행**

매핑 2단계

2 데이터 필터링 및 liftover

척추·관절·근육 관련 질환만 선별하여 분석에 사용

OMIA 전체 질환 중 근골격·척추·관절 시스템과 직접적으로 연관된 phene만 필터링하여 리스크 분석 정확도를 높임

Reference Sequence 버전 차이를 **Liftover(Chain Map)**으로 보정

OMIA 변이의 genome assembly 버전이 서로 다를 경우 위치 오차가 발생하므로, UCSC Chain 파일 기반 liftover를 적용해 기준 버전 (CanFam3.1)으로 정규화함

2차: 정밀 필터링 전략

3가지 세분화 카테고리로 확실한 근골격계 질환만 선별

필터링 결과
▼ **527행 → 119개**

Chain 파일 매핑 결과

Original_CanFam3

90

LiftOver_UU_Cfam_GSD_1.0

17

LiftOver_Dog10K_Boxer_Tasha

8

3.1.2.매핑 3단계

3 OMIA-ENSEMBL 매핑

1. Ensembl GTF에서 gene feature만 추출해 BED 데이터 생성
GTF 파일 중 feature가 'gene'인 행만 선별하여 유전자 구간 정보를 얻음.

2. OMIA DB → Ensembl DB 유전자 구간 기반 매핑

OMIA 변이의 chr·pos 정보를 Ensembl GTF의 gene interval(chr-start-end)과 비교하여 가장 가까운 유전자에 매핑함.

GTF 파일 처리 결과

전체 GTF 행 수
1,397,974

gene feature만 필터링 후
30,951 행

유효 chr만 남긴 후
30,424 행

OMIA-Ensembl DB매핑 결과

ENSEMBL 매핑 성공 변이 수(행 기준)
108개

multi_gene_flag=True
(한 변이에 2개 이상 gene 매핑) 개수
26

어떤 gene에도 속하지 않은 OMIA 변이 수
4

매핑 4단계

4 OMIA-ENSEMBL-SNP 매핑

Gene interval 주변 SNP 위치와의 거리를 계산하여 연관성(LD) 있는 SNP 그룹을 매핑

1) 입력 데이터 규모

OMIA_ENS 변이 수: 108개

SNP 메타데이터 수: 477,903개

2) 직접 매핑 결과 (정확 chr·pos·rsID 기반)

rsID 매칭 성공: 0개

Chr-Position 직매칭 성공: 0개

(⇒ 개별 SNP과 OMIA 변이는 직접적 1:1 좌표 일치 없음)

최종 매핑 결과

Gene-interval 기반 SNP 매칭 성공 수
1,610개

최종 OMIA 변이 ↔ SNP 매핑 총 수
5,808개
(⇒ 하나의 OMIA 변이가 평균 약 53.7개 SNP와 연결됨)

대상 OMIA 변이
108

3.1.3.데이터 전처리

✓ 병합 검증

통합본과 원본 OMIA의 공통 컬럼 정렬 비교 → 원본 메타데이터 보존 확인.
병합 과정에서 유전자형 정보가 추가된 것 외에, 원래 메타데이터는 손상 없이 유지됨.

✓ 불필요 메타 삭제

위치/참조/중간 계산 등 21개 메타 컬럼 드랍 → 분석 핵심만 남김.
start, end, gene_count_per_variant 등 스코어링에 필요 없는 메타데이터 제거.

✓ 최종 스키마

약 6,315행 × 126열의 최종 정제 데이터 구조.
SNP ID, 질병 관련 정보, 개체별 유전자형 등 스코어링에 필요한 데이터만 담긴 파일 생성.

⚠ 경고 처리

혼합 dtype 경고는 명시적 dtype 설정으로 완화 권장. 일부 컬럼의 데이터 타입 혼합으로 인한 경고 발생, low_memory=False 옵션으로 임시 처리함.

✓ 재현성

파일 버전/로그 명시, 동일 결과 재생산 가능.
모든 전처리 단계를 기록하여 독립적인 환경에서도 동일한 결과를 얻을 수 있도록 함.

메타데이터 정제 결과

🗑 드랍된 메타데이터 컬럼 (21개)

start, end, gene_count_per_variant,
multi_gene_flag, chromosome_omia, genomic_coordinate,
reference_sequence, variant_id, gene_chr, gene_map_location,
gene_symbol_omia, gene_symbol_all, gene_symbol_ens, defect,
gb_species_id, combined_text, original_pos, method,
chromosome_x, match_method, allele

📊 데이터 크기 변화

6,315

총 SNP 수

147

병합 후 컬럼수

126

정제 후 컬럼수

94

개체 유전자형 수

✓ QC 최종 결론

최종 분석 데이터셋은 개체별 유전자형과 질병 정보를 보존하면서
불필요한 컬럼을 제거하여 데이터 크기를 14% 감소시킴.
이 데이터는 다음 단계인 유전적 위험도 스코어링을 위한
최적화된 입력 파일로 준비됨.

3.1.4. 성별 판정 시스템

유전체 QC 및 X-linked 질환 위험도 계산의 정확성을 확보하기 위해 성별을 먼저 판정

원리

X 염색체 마커의 이형접합률(Heterozygosity) 기반으로 성별을 판정하며, 수컷(XY)은 동형접합이 많고 암컷(XX)은 이형접합 비율이 높음.

임계값 로직

사전 정의된 임계치를 기준으로 Male/Female을 분류.

이형접합률이 낮으면 수컷, 높으면 암컷으로 판정하며, 결측 과다 시 보류 처리.

임계값: X-염색체 이형접합률 5% ($Heterozygosity > 0.05 \rightarrow Female$)

Genotyping Error를 감안해 설정한 보수적 기준

결과 분포

Male


59

Female

35

활용 방안

X-연관(XLR/XLD) MOI 해석의 전제 조건으로, Method 1/2에서 성별에 따라 유전자형 해석이 달라짐.



해당 로직은 determine_sex_robust 함수로 구현됨

Method 1은 개체의 유전병 발병 여부를 진단하기 위한 단계로, Clear / Carrier / At-risk 상태를 직접 판정하는 진단적 분석.

본 단계는 점수 계산이 아닌, 개체의 발병 여부를 판정하기 위한 Diagnosis 절차.

3.1.5. Method 1 – 멘델 유전병 분석(거리/상태 로직)

Mendelian Score 핵심 로직

유전 질환은 유전 방식(MOI : Mode of Inheritance) — AR(열성), AD(우성), X-linked — 에 따라 genotype를 Clear/Carrier/At-risk로 해석하는 게 기본 원칙

거리 필터

변이-유전자 간 거리가 20kb 이내인 경우만 질병 연관성을 인정.
이는 인과성을 판단하는 보수적인 기준으로, 원거리 변이의 오탐지 가능성을 최소화.
20kb 이내 거리 제한은 변이와 유전자 간 직접적인 인과성을 인정하기 위한 보수적 기준이며, 잘못된 매칭을 줄여 진단 정확도를 높이기 위한 필수 조건.

상태 부여

유전자형(0/1/2)과 MOI(멘델 유전양식), 성별을 모두 고려하여 각 개체의 상태를 판정.
판정 결과는 At-risk(위험), Carrier(보인자), Clear(정상) 중 하나로 산출.


- MOI(유전양식)에 따라 유전자형 해석이 달라짐:**
- 열성(Recessive): 2개 변이 시 At-risk, 1개는 Carrier
 - 우성(Dominant): 변이 1개라도 존재하면 At-risk (Mitochondrial 포함)
 - X-linked Male: 변이 존재 시 At-risk (X 염색체 1개)
 - X-linked Female: 열성 규칙 적용 (0=Clear, 1=Carrier, 2=At-risk)

A01 개체의 멘델 상태 분포

36	11	13
At-risk	Carrier	Clear

다중 SNP 처리

동일 질병에 여러 SNP가 연관된 경우, 가장 높은 위험 상태를 최종 결과로 채택.
위험도 순위는 At-risk > Carrier > Clear 순으로, 보수적인 위험 평가 원칙을 적용.
여러 SNP가 존재할 경우 At-risk > Carrier > Clear 순으로 위험도가 높은 상태를 최우선으로 채택.



※ MOI(우성/열성/X-linked/미토콘드리아)에 따라 상태 판정 기준이 다르게 적용.

3.1.5. Method 1 – MOI별 해석 규칙

상염색체 열성 (AR, Autosomal Recessive)

유전자형 2에서 At-risk 판정, 1은 Carrier, 0은 Clear로 분류.
열성 유전의 특성상, 두 대립 유전자 모두 변이형일 때만 질병 발현 가능성 존재.

상염색체 우성 (AD, Autosomal Dominant)

유전자형 1 또는 2에서 At-risk 판정, 0은 Clear로 분류.
우성 유전은 단 하나의 변이형 대립 유전자만으로도 질병 발현이 가능.

X-연관 유전 (XLR/XLD, X-linked)

수컷(♂)은 헤미지구성(hemizygous) 상태로 1에서 At-risk 가능,
암컷(♀)은 1=Carrier, 2=At-risk로 판정. X 염색체 유전은 성별에 따라 해석 기준이 다름.

수컷은 X 염색체가 하나뿐이므로 변이가 존재할 경우 바로 At-risk로 분류.

충돌 처리 방식

동일 질병에 대해 상충되는 SNP가 존재할 경우,
가장 보수적으로 At-risk > Carrier > Clear 순서로 위험도가 높은 상태를 우선 채택.

A01 샘플 상태 분포

36

At-risk

11

Carrier

13

Clear

MOI별 유전자형 해석 규칙

MOI	Genotype	Male	Female	해석
AR	0	Clear	Clear	정상
AR	1	Carrier	Carrier	보인자
AR	2	At-risk	At-risk	위험
AD	0	Clear	Clear	정상
AD	1	At-risk	At-risk	위험
AD	2	At-risk	At-risk	위험
XLR	0	Clear	Clear	정상
XLR	1	At-risk	Carrier	성별 차이
XLR	2	N/A	At-risk	암컷만 해당

● At-risk: 발병 위험 ● Carrier: 보인자 ● Clear: 정상

※ X-linked Female은 열성 유전 규칙을 따르며, Male과 Female의 해석 기준이 다름.

3.1.6. Method 2 – PRS 가중치 모델

$$PRS = \sum \text{SNP} [W_{\text{func}} \times W_{\text{dist}} \times W_{\text{gt}}]$$

여기서 $W_{\text{func}} \times W_{\text{dist}} \times W_{\text{gt}}$ 는 각 SNP의 효과크기(β)를 의미하고, W_{gt} 는 MOI를 반영해 보정된 유전자형 점수(G_{score})로 구현.

가중치 부여

1) 기능영향도 가중치

Variant Effect (영향도)	weight_function
Frameshift / Stop_gain / Stop_lost	1.0
Missense (Non-synonymous)	0.7
Splice region / UTR	0.4
Synonymous (Silent)	0.1
Unknown / 기타	0.2

* '단백질을 박살낼수록 점수를 크게'

2) 거리 기반 신뢰도 가중치

SNP-Gene 거리(bp)	weight_distance
0-50 bp	1.0
50-100,000 bp (100 kb)	0.7
100,000-200,000 bp	0.5
200,000-400,000 bp	0.3
400,000-1,000,000 bp	0.1
> 1,000,000 bp	제외(drop)

* "gene 중심에서 얼마나 가까운 SNP인가"

3) 유해성 가중치

Deleterious 구분	weight_deleterious
High / Yes	1.0
Medium	0.7
Low / No	0.3

* 'deleterious=Yes' 또는 high-impact 변이에 추가 가중치 부여

! 기능적 심각도 가중치 (Wfunc)

질병의 심각도와 유전자의 기능적 중요도를 반영한 가중치.
치명적 질환과 핵심 기능 유전자에 높은 가중치를 부여.
Frameshift·Nonsense > Splicing·In-frame deletion > Missense > Regulatory > 기타/NaN 순으로 ACMG 변이 병원성 가이드라인을 참고하여 2.0 ~ 0.1점의 단계적 가중치를 부여.

📍 거리 신뢰도 (Wdist)

SNP와 유전자 간 물리적 거리에 기반한 신뢰도.
거리가 가까울수록 높은 가중치가 부여되며, 20kb 이내의 변이를 중점적으로 평가. 거리 구간별로는 0~20kb: 1.0, 20~100kb: 0.7, 100~300kb: 0.4, 300kb~1Mb: 0.1, 1Mb 이상: 0.0으로 떨어지도록 설계.

⚖ 유전자형 기여도 (Wgt)

개체의 실제 유전자형(0, 1, 2)에 따른 기여도.
위험 대립형질의 수에 비례하여 가중치가 증가하며, 결측치(NaN)는 무기여(0) 처리. 열성 질환은 Carrier($G=1$)를 거의 0점(0.01)으로 낮추고 $G=2$ 에 점수를 집중하며, 우성·불완전우성은 가산 모델(0, 1, 2)을 적용. X-연관 및 미토콘드리아 유전은 성별에 따라 별도의 변환 규칙을 적용.

3.1.6. Method 2 – 정규화와 상대적 위험도

📊 Min-Max 정규화

```
PRS_norm = (PRS - PRS_min) / (PRS_max - PRS_min)
```

질병별로 개체 간 0~1 스케일로 정규화하여 코호트 내 상대 순위를 제공합니다. 모든 질병의 점수 범위를 동일하게 조정하여 비교 가능한 상대적 위험도로 변환.

📈 해석 방법

1에 가까울수록 해당 질병에 대한 상대적 위험이 높음.
즉, 0.8 이상은 상위 20% 위험군, 0.5는 평균적 위험,
0.2 이하는 하위 20% 저위험군으로 해석 가능.



⚠️ 편향 주의

샘플 수가 매우 적은 질병은 변동성이 높아 정규화 결과가 불안정할 수 있음.
최소 샘플 수 기준을 설정하여 통계적 유의성을 확보하는 것이 권장.

</> 구현 팁

컬럼 반복 삽입으로 인한 DataFrame 파편화 문제는
일괄 concat으로 성능을 개선할 수 있음.
특히 많은 샘플에 대해 정규화할 때 속도가 크게 향상.

정규화 전후 PRS 점수 비교




3.1.6. Method 2 – 기능적 가중치(Variant Effect) 설계 근거

기능적 가중치(W_func)는
실제 데이터의 variant-effect-name 분포를 기반으로 설계.

Frameshift, Nonsense, Splicing과 같은 고위험 변이가 총
분히 관찰되어, ACMG 병원성 기준에 따라 2.0~0.1의
단계 가중치를 부여.

※ 결측치(NaN) 비율도 실제로 확인하여, 정보가 부족한 변이는 가장 낮은 가중치로 설정.



순위	값	개수	비율(%)
1	NaN (결측치)	1,803	31.04%
2	frameshift	1,437	24.74%
3	nonsense (stop-gain)	1,106	19.04%
4	missense	760	13.09%
5	splicing	632	10.88%
6	regulatory	63	1.08%
7	deletion (in-frame)	7	0.12%

3.1.6. Method 2 – MOI 및 유전자형 가중치 설계 근거

MOI 가중치(W_MOI)와 유전자형 보정점수(Gscore')는 실제 OMIA moi_code 분포를 기반으로 설계. 상염색체 우성·불완전 우성은 가산 모델(0,1,2)에 적합하여 그대로 적용하고, 열성 유전(AR 계열)은 G=1 보인자 위험도를 0.01로 낮추어 표현형 중심 PRS 목적에 맞게 보정. X-linked와 Mitochondrial 유전은 성별·모계 유전 특성을 반영해 별도의 변환 규칙을 적용.

📊 MOI 유형별 특성

- 상염색체 우성(AD): 한 개 변이만으로도 표현형 발현
- 상염색체 열성(AR): 두 개 변이 필요, 보인자는 무증상
- X-연관 유전(XLR): 성별에 따라 다른 발현 양상
- 미토콘드리아(MIT): 모계 유전, 다양한 발현 정도

📊 유전자형 점수 보정

- AR 열성: G=1 → 0.01, G=2 → 1.0
- AD 우성: G=0 → 0, G=1 → 1.0, G=2 → 1.0
- X-linked: 성별에 따른 별도 계산
- MIT: 존재 시 모든 자손에게 영향




그림 1: moi_code 분포 차트 - XLR(X-linked recessive)과 AR(Autosomal Recessive) 비중이 가장 높음

순위	값	개수	비율(%)
1	XLR	3,892	67.01%
2	R	1,428	24.59%
3	NaN (결측치)	176	3.03%
4	PR	127	2.19%
5	A	121	2.08%
6	D	38	0.65%
7	MIT	20	0.34%
8	AID	6	0.10%


그림 2: moi_code 분포 테이블 - XLR(67.01%), R(24.59%) 순서

각 Name별 대응되는 Code 개수:			
Autosomal	→	✓ 1:1	A
Autosomal dominant	→	✓ 1:1	D
Autosomal incomplete dominant	→	✓ 1:1	AID
Autosomal recessive	→	✓ 1:1	R
Mitochondrial	→	✓ 1:1	MIT
Probably autosomal recessive	→	✓ 1:1	PR
X-linked recessive	→	✓ 1:1	XLR

그림 3: 각 MOI 코드별 대응되는 유전 양식 (1:1 매핑)

3.1.6. Method 2 – deleterious 가중치를 제외한 이유

deleterious 컬럼은 대부분이 결측치(NaN)이며,
특정 알고리즘에만 예측값이 존재하는 편향이 발견되어
PRS 모델에서 제외하는 것이 통계적으로 타당하다고 판단.
대신 기능적 가중치(W_func)가 변이의 실제 손상도 차이를
안정적으로 반영하도록 설계.



deleterious 컬럼 분포 - 'yes' 5,764건(99.24%), 'unknown' 44건(0.76%)

순위	값	개수	비율 (%)
1	yes	5,764	99.24%
2	unknown	44	0.76%

대다수가 *NaN*이며 특정 알고리즘 편향 존재

3.1.7. Method 3 – 시스템 부담 점수

정의 및 목적

Method 3은 신체 시스템 단위로 위험도를 통합하여 '이 개체가 어떤 시스템에 가장 취약한가?'를 직관적으로 보여주기 위한 단계.

Burden Score 로직

System Tag 부여 → SNP 위험도 합산 → System 간 SNP 수 보정 ($\sqrt{\text{정규화}}$) → System-level ranking
→ Actionable risk 생성

RAW/NORM 이중 지표

RAW: 무상한(unbounded) 총합으로, 시스템 내 절대적인 유전 부담 총량을 나타냄.
NORM: 0~1 사이로 정규화된 지표로, 코호트 내 다른 개체들과의 상대적 비교에 활용.

RAW 점수는 유전적 변이의 절대적 부하량을 의미하며, NORM 점수는 개체가 집단 내에서 어느 정도 위치(0~1)를 차지하는지 나타냄. 두 지표를 함께 사용해 절대 위험과 상대적 취약점을 동시에 파악 가능.

해석 방법


개체 내에서 가장 높은 점수를 받은 시스템이 유전적으로 가장 취약한 부위로 판단.
이 정보는 예방 검진 우선순위, 생활 및 운동 가이드라인, 번식 위험 회피 전략 수립에 활용 가능.
질병마다 관여하는 변이 수가 달라 단순 합산 시 특정 시스템 점수가 과도하게 커질 수 있음.
이를 방지하기 위해 Min-Max Scaling을 적용하여 시스템 간 점수 범위를 통일함.
이로 인해 개체별 취약 부위를 명확하게 비교 가능.

샘플 A01 분석 사례

• spine_neuro: RAW 7.43 (NORM 0.675) - 가장 취약 • joint: RAW 4.94 (NORM 0.585) - 중간 • muscle: RAW 4.75 (NORM 0.371) - 양호

RAW는 시스템에 쌓인 유전적 변이량(절대 부하)이며, NORM은 신체 시스템 내에서 해당 개체의 상대적 건강 순위를 의미. 두 점수를 함께 보면 가장 약한 부위를 정확히 알 수 있음.

샘플 A01의 시스템별 부담 점수



3.2.데이터 분석(개체 간 유사 품종 분석)

유전체 데이터 분석 파이프라인의 작업 흐름 및 목적

**기술 스택**

 Python

 Pandas, numpy

 Scikit-learn

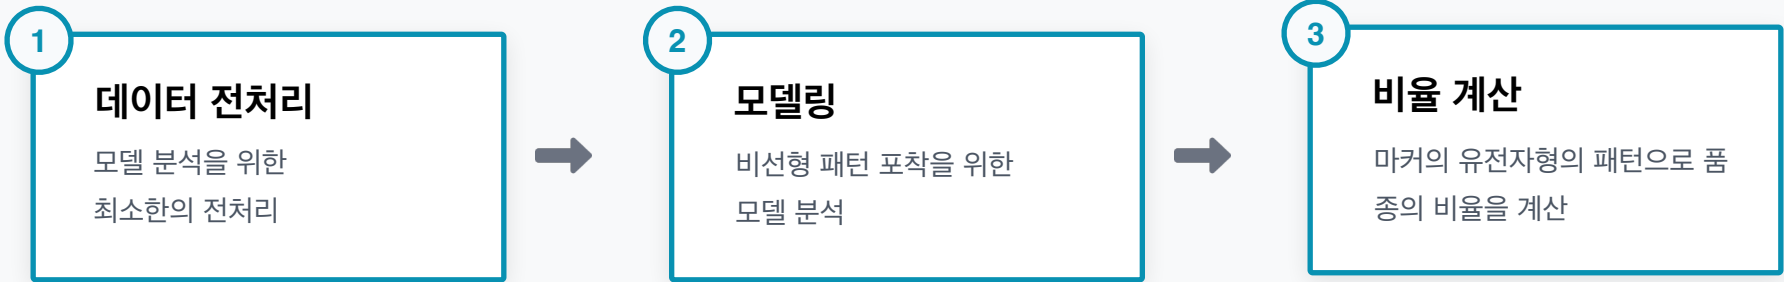
 PCA, t-SNE, UMAP, K-means

 Matplotlib, seaborn


**분석 전략**

소수의 품종 마커는 다른 연구 집단에서 정의된 가이드라인.
개체의 유전 역사가 가이드라인과 다를 수 있으므로,
편향을 배제하고 모든 SNP들이 보여주는 가장 큰 유전적 거리를
우선적으로 파악하는 전략을 취함(모든 마커 기준)

분석 파이프라인



3.2.1.데이터 전처리



피처 엔지니어링

분산 상위 20%/10% 고분산 SNP만 선택적으로 사용
→ 정보량이 높은 변이만 선별하여 분석 효율성 극대화

재현 가능한 파이프라인

각 단계는 파이썬 모듈로 분리 구현되어 일관성 유지
→ 엔드투엔드 데이터 처리 과정 완전 자동화 및 검증 가능


전처리 결과 요약

샘플 수: 94개 최종 SNP: 약 425,863개

모든 단계는 *scikit-learn* 파이프라인으로 통합되어 자동화된 워크플로우 구성


3.2.2.모델링 – PCA 분석

분산 = 0인 SNP 제거 + 정규화




최적 방법

상위 20% SNP 선별



상위 10% SNP + k ≈ 30



3.2.2.모델링 – PCA 분석

항목	1차 PCA	2차 PCA	3차 PCA
전처리	기본	상위 20%	상위 10%
최적 k	10	10	22
Silhouette	0.489	0.523 	0.503
PC1 설명력	4.34%	5.76%	5.10%
PC2 설명력	3.80%	4.88%	11.21%
총 설명력	8.14%	10.64%	16.31%
군집 분리	불명확	개선	밀집

변화

- 데이터 필터링을 강화할수록(10%) PC2 설명력이 크게 증가하며, 총 설명력은 16.31%까지 향상
- 상위 20% 변수 선별이 최적의 Silhouette 점수(0.523)를 제공, 군집 분리도 개선

분석 결론 및 한계점

2차 PCA가 Silhouette Score 측면에서 최선 (0.523)


하지만 모든 단계에서 PC1+PC2 총 설명력 < 17% (매우 낮음)

군집 분리가 명확하지 않음

3.2.2.모델링 – 모델 비교(PCA / t-SNE / UMAP)

PCA

선형 차원 축소




설명력: **PC1+PC2 ≈ 8%** Silhouette: **0.4888 (k=10)**

최적 모델

t-SNE


비선형 차원 축소 (perplexity=5)



Silhouette: **0.6835 (k=15)** 분리도: **높음**

UMAP

비선형 차원 축소



Silhouette: **≈0.62 (k=15)** 분리도: **중상**


비선형 차원 축소 비교

- t-SNE: 가장 뚜렷한 군집 분리, 최고 silhouette 점수(0.68+), 소형 군집도 안정적 검출
- UMAP: 높은 분리도, 군집 구조 보존 양호, t-SNE와 유사한 패턴이나 성능은 다소 낮음
- PCA: 낮은 설명력, 샘플 밀집도 높음, 복잡한 비선형 관계 포착 어려움


뚜렷한 군집 분리의 t-SNE 채택

3.2.2.모델링 – t-SNE(marker: all vs only breed)

모든 마커 + 고분산 SNP 20%



품종 마커 + 고분산 SNP 20%



품종 마커 + 고분산 SNP 20%
+ 하이퍼 파라미터 튜닝



3.2.2.모델링 – t-SNE(marker: all vs only breed)

구분	전체 마커 고분산 20%	품종 마커 고분산 20%	품종 마커 + 고분산 20% + 하이 퍼 파라미터 튜닝
데이터셋	모든 마커	품종 마커만	품종 마커만
피쳐 엔지니어링	고분산 SNP 상위 20%	고분산 SNP 상위 20%	고분산 SNP 상위 20%
결측치 처리	Most Frequent	Most Frequent	Median
Perplexity (P)	5~40 탐색	5~40 탐색	min(30, N-1) 자동계산
max_iter	1000	1000	1500
learning_rate	auto	auto	auto
K 탐색 범위	3~30	3~30	2~10
KMeans init	기본값	기본값	k-means++
최적 K	10	3	5
Silhouette Score	0.796	0.796	0.375

💡 Score가 높더라도 불균형 클러스터는 실용적이지 않음 → 믹스견 데이터라 분리가 어려움

3.2.3.비율 계산 – 품종 기여 비율 추정 방법론

분석 방법론

- 1 데이터 전처리 및 품종명 추출**
ID 형식 필터링: 'b'로 시작하고 '_' 포함된 유효 행만 선택
핵심 함수: `extract_breed()` 로 순수 품종명 추출
- 2 마커 개수 QC 필터링**
MIN_MARKERS = Q1: 하위 25% 미만 마커 수의 품종 제외
근거: 정보량 부족 품종 배제로 통계적 안정성 확보, 노이즈 영향 최소화
- 3 품종 일치도 계산 및 가중치**
Raw Score: 유전자형 일치도 계산 (값 1,2 평균, 결측치 -1 제외)

Normalized Score = Raw Score × ln(Marker Count)

근거: 마커 수 많을수록 품종 신뢰도↑, 로그변환 가중치
- 4 품종 구성 비율 추정**
비율화: 모든 품종 정규화 점수 합계로 나누어 계산
결과 표현: 상위 5개 품종만 추출하여 결과 테이블 생성
- 5 유전학적 근거 기반 순종 판단**

임계값 75%: 순종과 F1 잡종 교배 시 순수혈통 기대 비율
유전학적 기준 "최소 2세대 해당 품종 혈통 유지" 엄격 적용


참조 품종 데이터

총 분석 개체: 94마리


원천 참조 품종: 113개 → 필터링 후: 85개

필터링 기준: Q1(하위 25%) 마커 개수 미만 제외


1위 품종 기여율 분포



최다 기여 품종 Top3



순종/믹스 분류 결과



💡 결론

데이터셋 전체가 순종으로 보기 어려운 믹스견으로 구성되어 있으며, 평균/중앙값 기여율이 10% 미만으로 매우 낮아 다양한 품종의 유전적 기여를 받은 복잡한 믹스견 집단임을 강력하게 시사함

4.1. 최종 산출물 : Streamlit

개체 선택

품종 분석 및 품종과 연동한 자동 이미지 제작

메뉴 이동

설정

분석할 강아지 선택

D02


D02
대표 품종: Pomeranian

메뉴 선택

종합 요약

신체 부위별 취약성

유전 질환 상세 가이드

홈 케어 가이드

AI 상담소

전문가용 리포트

D02 유전 건강 종합 리포트

1. 메델리안 상태 분포 (Method 1)

At-risk

Carrier

Clear

55.4%

25%

19.6%

발병 위험(At-risk): 31건

보인자(Carrier): 14건

해당 개체가 보유한 Mendelian Status 모아 보기

2. 주요 주의 질환 Top 5 (Method 2 PRS)

다발성 골연골종증

(also called: multiple osteochondromas, multiple hereditary exostoses, multiple cartilaginous exostoses, diaphyseal aclasis and hereditary deforming chondrodysplasia)

관련 부위: 척추/신경 (Spine/Neuro) · Risk Score: 1.000

섬유소성 백질이영양증, 섬유소성 뇌척수병증

(Fibrinoid leukodystrophy, fibrinoid encephalomyelopathy)

관련 부위: 척추/신경 (Spine/Neuro) · Risk Score: 1.000

상염색체 우성 중심핵 근병증

(Autosomal dominant centronuclear myopathy)

관련 부위: 근육 (Muscle) · Risk Score: 0.702

알파-사르코글리칸병 (LGMD2D)

(LGMD2D; alpha-sarcoglycanopathy)

관련 부위: 근육 (Muscle) · Risk Score: 0.504

유전성 운동실조증

(hereditary ataxia)

관련 부위: 척추/신경 (Spine/Neuro) · Risk Score: 0.459

보유 유전질환 중 PRS score 높은 상위 5가지

4.1. 최종 산출물 : Streamlit



4.1. 최종 산출물 : Streamlit

설
분석할 강아지 선택
D02
대표 품종: Pomeranian
메뉴 선택
종합 요약
신체 부위별 취약성
유전 질환 상세 가이드
홈케어 가이드
AI 상담소
전문가용 리포트

유전 질환 상세 가이드

상세 정보를 확인할 질환을 선택하세요:

Autosomal dominant centronuclear myopathy

Autosomal dominant centronuclear myopathy
Congenital hypothyroidism with goiter
Congenital mirror movement disorder 1
Congenital myasthenic syndrome
Congenital myasthenic syndromes
Dandy-Walker-like malformation; inferior cerebellar hypoplasia
Fetal-onset neuroaxonal dystrophy

니다. Böhm et al. (2022)에 의해 영향을 받는 개들은 DNM2 CNM 개로 명명되었습니다. 이 질환은 주로 근육 약화와 관련된 증상을 나타내며, 다양한 근육 그룹에 영향을 미칠 수 있습니다. 유전적 요인으로 인해 가족 내에
서 발생할 수 있으며, 이는 보호자에게 유전 상담의 필요성을 시사합니다.

유전/병리 기전 및 위험 인자

자식 우성 중심핵 근병증은 DNM2 유전자의 변이에 의해 발생합니다. 이 유전자는 근육 세포에서 중요한 역할을 하는 단백질을 생성하는데, 이 단백질은 근육 세포의 구조적 안정성을 유지하는 데 필수적입니다. DNM2 유
전자의 변이가 발생하면 근육 세포가 정상적으로 기능하지 못하게 되어 근육 약화가 발생합니다. 이 질환은 자식 우성으로 유전되므로, 부모 중 한 명이 변이를 가지고 있다면 자녀에게 이 질환이 전파될 가능성이 있습니
다. 따라서, 이 질환의 발병 원인을 이해하는 것은 조기 진단과 관리에 매우 중요합니다.

주요 증상 및 발병 시기

LLM 모델을 결합하여 해당 개체가 보유한 모든 유전질환(PHENE)에 대한 상세한 설명 제공

4.1. 최종 산출물 : Streamlit

설
분석할 감아지 선택
D02

D02

대표 품종: Pomeranian

메뉴 선택

종합 요약

신체 부위별 취약성

유전 질환 상세 가이드

홈 케어 가이드

AI 상담소

전문가용 리포트

전문가용 상세 리포트 (최적화 버전)

Mendelian Risks Method1 Raw D02 OMIA-SNP 매핑 RAW (최적화)

D02 OMIA-SNP 매핑 RAW (LD proxy 기반)

다운로드

검색

리셋

	phene_name	phene_id	gene_id	gene_symbol_ens	variant_effect_name	dbSNP_rs_id	chromosome_y	snp_start	distance_bp	reference_seq
85068	Autosomal dominant centronuclear myopathy	4936	ENSCAFG000000017651	DNM2	missense	rs851678356	20	50419485	4012	CanFam3.1
85086	Autosomal dominant centronuclear myopathy	4936	ENSCAFG000000017651	DNM2	missense	rs22865586	20	50436008	12511	CanFam3.1
85056	Autosomal dominant centronuclear myopathy	4936	ENSCAFG000000017651	DNM2	missense	rs22865587	20	50436336	12839	CanFam3.1
85062	Autosomal dominant centronuclear myopathy	4936	ENSCAFG000000017651	DNM2	missense	rs22865591	20	50437330	13833	CanFam3.1
85080	Autosomal dominant centronuclear myopathy	4936	ENSCAFG000000017651	DNM2	missense	None	20	50441081	17584	CanFam3.1
85074	Autosomal dominant centronuclear myopathy	4936	ENSCAFG000000017651	DNM2	missense	rs22865597	20	50464885	41388	CanFam3.1
110129	Canine degenerative myelopathy, hereditary canine spinal muscular atrophy	506	ENSCAFG000000008859	SOD1	missense	None	31	26537149	3193	CanFam3.1
109483	Canine degenerative myelopathy, hereditary canine spinal muscular atrophy	506	ENSCAFG000000008859	SOD1	missense	rs23703324	31	26550871	10529	CanFam3.1
109789	Canine degenerative myelopathy, hereditary canine spinal muscular atrophy	506	ENSCAFG000000008859	SOD1	missense	rs23695325	31	26552840	12498	CanFam3.1
109755	Canine degenerative myelopathy, hereditary canine spinal muscular atrophy	506	ENSCAFG000000008859	SOD1	missense	None	31	26525304	15038	CanFam3.1
110163	Canine degenerative myelopathy, hereditary canine spinal muscular atrophy	506	ENSCAFG000000008859	SOD1	missense	None	31	26513961	26381	CanFam3.1
109449	Canine degenerative myelopathy, hereditary canine spinal muscular atrophy	506	ENSCAFG000000008859	SOD1	missense	rs23680093	31	26513704	26638	CanFam3.1
109551	Canine degenerative myelopathy, hereditary canine spinal muscular atrophy	506	ENSCAFG000000008859	SOD1	missense	rs23703188	31	26570787	30445	CanFam3.1
109959	Canine degenerative myelopathy, hereditary canine spinal muscular atrophy	506	ENSCAFG000000008859	SOD1	missense	rs23678666	31	26509811	30531	CanFam3.1
109687	Canine degenerative myelopathy, hereditary canine spinal muscular atrophy	506	ENSCAFG000000008859	SOD1	missense	None	31	26572743	32401	CanFam3.1
109857	Canine degenerative myelopathy, hereditary canine spinal muscular atrophy	506	ENSCAFG000000008859	SOD1	missense	None	31	26504240	36102	CanFam3.1
109517	Canine degenerative myelopathy, hereditary canine spinal muscular atrophy	506	ENSCAFG000000008859	SOD1	missense	None	31	26580168	39826	CanFam3.1

수의사를 위하여 Mendelian Score 제공
Phene 별로 매칭된 SNP 마커 중
At-risk/Carrier 상태인 마커를 모두 보여주며,
Omia Pos와 Snp Pos의 거리가 가장 가까운 순으로 데이터 제공.
(항후 r^2 계수로 기준 변경 예정)

4.2. 회고록 – 핵심 발견 & 기술적 교훈

1 🔍 핵심 발견

전체 개체가 믹스건으로 확인

- 94개 중 순종 0% (임계값 75% 기준)
- 품종 기여율 + 군집 패턴으로 복잡한 유전적 혼합 패턴 확인

t-SNE가 PCA 대비 우수한 성능

- PCA: 총 설명력 < 17% (선형 한계)
- t-SNE: Silhouette 0.6835, 뚜렷한 군집 분리
- 비선형 패턴 포착에 효과적

💡 비선형 차원 축소 기법이 복잡한 유전적 패턴을 더 효과적으로 식별할 수 있음을 확인

💡 수치와 실제의 괴리

역설적 상황

품종 마커 K=3

Score 0.796

수치상 최고이나 97.9%가 한 클러스터에 몰림

클러스터 0에 97.9% (92개) 몰림 → 극단적 불균형

하이퍼파라미터 튜닝 후

Score 하락

0.375

하지만 5개 클러스터로 균형잡힌 분포 달성



5개 클러스터 균형적 분포, 품종별 구분 성공

교훈

- ✗ 높은 Score ≠ 좋은 군집화
- ✓ 분포 확인과 시각화 필수
- ✓ 해석 가능성 > 수치 최적화
- ℹ 믹스건은 완벽한 분리가 어려움

4.2. 회고록 – 분석 과정의 교훈

1 데이터 구조 이해의 중요성

초기 문제

- 대용량 유전체 데이터의 컴퓨팅 자원 한계
- 단순 행 병합, 파일 포맷 변환의 비효율

해결 과정

- 무작정 처리하기보단 "데이터 구조 발견"에 집중
- SNP의 패턴과 특성 파악
- 도메인 이해를 통한 효율적 전처리 설계

교훈

- ✓ 도메인 지식이 데이터 엔지니어링 효율성을 결정
- ✓ 구조를 이해하면 처리 전략이 명확해짐
- ✓ 컴퓨팅 자원보다 전략이 먼저

2 맹목적 레퍼런스 적용의 위험성

시행착오

- GWAS, Plink 등 표준 툴/가이드라인 적용 시도
- 데이터 구조 이해 없이 레퍼런스만 따름
- 어떤 값을 넣어야 할지 판단 불가

교훈

- ✓ 레퍼런스는 가이드일 뿐, 정답이 아님
- ✓ 데이터 구조를 계속 뜯어보는 자세 필요
- ✓ 원리 이해 → 적용 → 검증의 순서 중요

3 QC 기준과 분석 목적의 조화

초기 접근

- 일반적 유전체 QC 마커 기준 적용
- MAF, HWE, Call Rate 등 표준 필터링

문제 발견

- QC로 마커 삭제 시 희귀 변이도 함께 소실
- 믹스견 분석에는 희귀 변이도 중요한 정보

교훈

- ✓ 표준 QC ≠ 항상 최선
- ✓ 분석 목적에 맞는 유연한 전처리 필수
- ✓ 맹목적 툴 적용보다 도메인 이해 우선